

EVENT EXTRACTION FROM POLITICAL-THEMED NEWS

GVHD: TS. Đỗ Trọng Hợp - CN. Nguyễn Thị Hoàng Anh

Thành viên nhóm:

22520505 - Kiều Quý Hùng

22520752 - Nguyễn Duy Liêm

22521123 - Mạc Nguyên Phúc

I. INTRODUCTION

- Xây dựng pipeline tự động thu thập tin tức từ các trang báo Việt nam, trích xuất sự kiện chính trị có cấu trúc bằng mô hình học máy, và phân phối qua Apache Kafka để phục vụ các ứng dụng phân tích thời gian thực.
- Chuyển văn bản phi cấu trúc thành dòng sự kiện có cấu trúc, giúp việc truy vấn, thống kê, giám sát chính trị trở nên dễ dàng và hiệu quả.



II. RELATED WORK

1

Nguyen, Thi-Nhung, et al. "BKEE: Pioneering Event Extraction in the Vietnamese Language." Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024).

2

Doddington, George R., et al. "The automatic content extraction (ace) program-tasks, data, and evaluation." Lrec. Vol. 2. No. 1. 2004.

3

Xiang, Wei, and Bang Wang. "A survey of event extraction from text." IEEE Access 7 (2019): 173111-173137.


III. METHODOLOGY

1 DATA CONSTRUCTION

2 MODEL

3 APACHE KAFKA

III. METHODOLOGY



Bài toán trích xuất sự kiện từ văn bản chính trị tiếng Việt bao gồm ba tác vụ chính:

- 1 phân loại loại sự kiện đang diễn ra trong câu
- 2 phát hiện từ kích hoạt sự kiện (trigger)
- 3 trích xuất các thành phần tham gia sự kiện (arguments) như chủ thể, đối tượng, thời gian, địa điểm.

Mục tiêu là xây dựng một mô hình có thể thực hiện đồng thời cả ba tác vụ này từ một câu đầu vào, nhằm chuyển đổi thông tin phi cấu trúc thành dạng có tổ chức phục vụ phân tích và giám sát tự động.

I. DATA CONSTRUCTION

I.1 Data Collection:

Dữ liệu được thu thập từ các bài báo chính trị tiếng Việt, lấy từ nguồn báo chính phủ thông qua công cụ web crawler.


Nội dung được xác thực từ quyết định, thông cáo, chỉ đạo cơ quan nhà nước, đảm bảo tính pháp lý và độ tin cậy cao nhất cho thông tin chính trị, kinh tế – xã hội và điều hành.

Thuộc tính	Nội dung
url	Liên kết dẫn đến bài báo
publish_date	Ngày đăng
title	Tiêu đề bài báo
summary	Tóm tắt nội dung chính bài báo
event_type	Sự kiện chính xảy ra trong summary
trigger	Từ kích hoạt sự kiện
arg_subject	Chủ thể thực hiện hành động hoặc nhân vật chính của sự kiện
arg_time	Mốc thời gian xảy ra sự kiện (ngày, giờ, khoảng thời gian...)
arg_location	Nơi diễn ra sự kiện (tên quốc gia, thành phố, cơ quan, địa danh...)

I. DATA CONSTRUCTION

I.2 Data Annotation:

- Dữ liệu được gán nhãn cho hai tác vụ: Event Detection (Event type classification và Trigger tagging) và Event Argument Extraction.
- Đạt độ đồng thuận 73,9% cho tác vụ event extraction và 75,1% cho tác vụ event argument extraction trên 100 mẫu dữ liệu ngẫu nhiên trong 10% dữ liệu. Sau đó tiếp tục gán nhãn riêng lẻ cho lượng còn lại trong 10% .
- 90% còn lại được gán nhãn tự động bằng Gemini 2.5 Flash với prompt thiết kế sẵn.
- Tập dữ liệu sau gán nhãn gồm trigger, loại sự kiện và các argument subject, location và time.
- Dữ liệu hoàn thiện phục vụ huấn luyện và đánh giá mô hình, gồm 5814 điểm dữ liệu.



I. DATA CONSTRUCTION

Guideline sử dụng để prompt cho LLM gồm 11 phần, bao gồm các điểm chính:

- **Thiết lập nhân dạng và mục tiêu rõ ràng.** Mục tiêu là gán nhãn chính xác một lô dữ liệu theo schema và quy tắc đã cho.
- **Phân tách các task có thứ tự và ràng buộc, chia nhỏ thành từng bước:** trigger, loại sự kiện, chủ thể, thời gian, địa điểm. Các ràng buộc giúp tránh mô hình bịa thông tin.
- **Định dạng chuẩn đầu ra và kiểm tra toàn vẹn:** LLM phải xuất đầu ra dưới dạng mảng JSON đúng định dạng, đúng kiểu dữ liệu. Bắt buộc số lượng phần tử đầu ra phải bằng với đầu vào để đảm bảo xử lý theo lô ổn định.
- **Hướng dẫn rõ ràng, sử dụng ít nhất 3 ví dụ cho từng event-type (few-shot).**

I. DATA CONSTRUCTION


I.3 Data Preprocessing:

- Dữ liệu được làm sạch bằng cách loại bỏ các dòng thiếu thông tin hoặc không khớp giữa tokens và nhãn BIO.
- Các trường dữ liệu được chuyển về dạng danh sách và chuẩn hóa nhãn bằng bảng ánh xạ số.
- Dữ liệu được chia train, dev, test theo phân phối nhãn có tầng và kiểm tra tần suất để đảm bảo đầy đủ, cân bằng các nhãn quan trọng.

I. DATA CONSTRUCTION

I.4 Data Statistics:


- Biểu đồ thể hiện phân bố nhãn trong 10% dữ liệu ngẫu nhiên được gán nhãn thủ công, với Meeting và Statement chiếm số lượng lớn nhất (174 và 76 mẫu).
- Sự lệch nhãn này do dữ liệu thô ban đầu chủ yếu là các bài báo về các cuộc họp, gặp gỡ ngoại giao và phát biểu chính trị, nên dù chọn ngẫu nhiên, phân bố nhãn vẫn giữ tính thiên lệch tương tự dữ liệu gốc.



I. DATA CONSTRUCTION

I.4 Data Statistics:

So với phân phối 10% dữ liệu gán nhãn thủ công, phân phối toàn bộ dữ liệu sau khi bổ sung nhãn bằng LLM vẫn giữ được xu hướng nhãn nhất quán. Đồng thời, số lượng dữ liệu ở các nhãn ít phổ biến tăng đáng kể, giúp cân bằng phân bố. Việc áp dụng few-shot với guideline rõ ràng giúp LLM duy trì chất lượng ổn định và tiết kiệm thời gian, chi phí so với gán nhãn thủ công.



2. METHODOLOGY

2.1. Approaches

Tiếp cận Pipeline (Tuần tự):

- Trong phương pháp này, chúng tôi sẽ phát triển các mô hình riêng biệt cho từng tác vụ con của trích xuất sự kiện và mỗi mô hình được thiết kế để xử lý một tác vụ cụ thể một cách độc lập.

Tiếp cận Joint-learning (Học chung):

- Phương pháp này sử dụng một mô hình duy nhất để học và suy luận đồng thời cả ba tác vụ con. Mục tiêu của cách tiếp cận này là để giảm thiểu sự lan truyền lỗi (error propagation) từ tác vụ này sang tác vụ khác và tận dụng sự phụ thuộc lẫn nhau vốn có giữa chúng.

2. MODELS

2.3. Implementation Method

- Phân loại thể loại Sự kiện (Event Type Classification)
- Gán thẻ kích hoạt (Trigger Tagging)
- Nhận diện các lập luận (Event Arguments Extraction)

3. APACHE KAFKA

15

Apache Kafka là gì?

- Apache Kafka là một hệ thống truyền tải dữ liệu sự kiện phân tán theo thời gian thực, hoạt động theo mô hình publish-subscribe, cho phép các ứng dụng gửi và nhận dữ liệu dạng message một cách linh hoạt, tách rời giữa các thành phần trong hệ thống.

Các thành phần chính:

- Apache Kafka gồm các thành phần chính: Producer gửi message vào Topic; Topic phân loại và lưu trữ message theo chủ đề; Broker quản lý và lưu trữ Topic cùng message; Consumer nhận và xử lý message theo thời gian thực hoặc theo nhóm; Zookeeper (hoặc Kafka Raft) điều phối, quản lý trạng thái và giám sát Broker, đảm bảo tính nhất quán cho hệ thống.

IV. EXPERIMENT

I. Evaluation Metrics:

- **BLEU:** Đo mức độ tương đồng giữa câu tóm tắt của mô hình và câu tham chiếu dựa trên sự khớp n-gram. Chỉ số càng cao, chất lượng sinh văn bản càng tốt.
- **ROUGE:** Đo mức độ bao phủ nội dung giữa câu dự đoán và câu tham chiếu dựa trên số lượng n-gram trùng lặp. Thường dùng trong đánh giá tóm tắt văn bản.
- **Precision:** Tỷ lệ đúng trong số các dự đoán mà mô hình đưa ra. Cho biết phần dự đoán đúng trên tổng số dự đoán.
- **Recall:** Tỷ lệ đúng trong số các trường hợp thực tế. Cho biết phần dự đoán đúng trên tổng số dữ liệu thực sự cần phát hiện.
- **F1-score:** Trung bình hài hòa giữa Precision và Recall. Chỉ số này cân bằng giữa khả năng dự đoán đúng và khả năng bao phủ của mô hình, đặc biệt hữu ích khi dữ liệu mất cân bằng.

2. Prompting results

Gemini 2.5 Flash đạt F1-score cao với các sự kiện phổ biến và đặc trưng rõ như Meeting, Visiting, Condolence. Một số sự kiện như Statement, Recognition có kết quả thấp do số mẫu ít và từ vựng phân tán. Nhìn chung, Recall cao ở nhiều loại sự kiện cho thấy khả năng bao phủ tốt, nhưng Precision còn hạn chế ở một số nhóm.

Event type	Precision	Recall	F1-score	Support
Celebration	0.75	0.52	0.62	23
Commemoration	0.69	0.8	0.74	25
Condolence	1	1	1	14
Cooperation	0.74	0.61	0.67	23
Diplomatic Reception	0.69	0.97	0.8	38
Government Formation	0.66	0.97	0.79	38
Inspection	0.57	0.89	0.7	18
Legislation	0.53	0.87	0.66	30
Meeting	0.81	0.64	0.71	174
Proposal	0.51	0.83	0.63	23
Publication	0.54	0.93	0.68	15
Recognition	0.53	0.71	0.61	14
Statement	0.84	0.39	0.53	82
Visiting	0.77	0.68	0.72	40

2. Prompting results

Gemini 2.5 Flash dự đoán tốt với các sự kiện có số mẫu lớn như Meeting (111/174), Diplomatic Reception (37/38), và Government Formation (37/38). Tuy nhiên, xảy ra nhầm lẫn nhiều giữa các nhóm có ngữ nghĩa gần như Statement, Publication và Recognition.

Confusion Matrix for Event Type

Celebration	12	8	0	0	0	0	0	0	3	0	0	0	0	0
Commemoration	1	20	0	0	0	0	0	0	3	0	0	0	0	1
Condolence	0	0	14	0	0	0	0	0	0	0	0	0	0	0
Cooperation	0	0	0	14	1	0	1	0	1	1	0	5	0	0
Diplomatic Reception	0	0	0	0	37	0	0	0	1	0	0	0	0	0
Government Formation	1	0	0	0	0	37	0	0	0	0	0	0	0	0
Inspection	0	0	0	0	0	0	16	2	0	0	0	0	0	0
Legislation	0	0	0	0	0	2	1	26	0	0	0	0	1	0
Meeting	0	0	0	2	10	11	6	19	111	3	2	1	3	6
Proposal	0	0	0	1	0	0	1	1	0	19	0	0	1	0
Publication	0	1	0	0	0	0	0	0	0	0	14	0	0	0
Recognition	1	0	0	1	1	0	0	0	0	0	1	10	0	0
Statement	0	0	0	1	0	6	3	1	14	14	8	2	32	1
Visiting	1	0	0	0	5	0	0	0	4	0	1	1	1	27

2. Prompting results

- Gemini 2.5 Flash đạt chỉ số ROUGE cao (0.82–0.91) với các argument thực thể như `arg_subject`, `arg_time` và `arg_location`, cho thấy khả năng nhận diện và trích xuất thông tin chính xác.
- Các thực thể như tên riêng, thời gian và địa điểm được mô hình nhận diện tốt nhờ đặc điểm từ vựng rõ ràng và ít biến đổi.
- Hiệu suất trích xuất trigger thấp hơn do đây là thành phần mang tính ngữ nghĩa và ngữ cảnh cao, khó xác định bằng đối sánh từ vựng thuần túy.
- BLEU thấp (0.192) ở trigger phản ánh sự khác biệt về cách diễn đạt dù nội dung tương đương, dẫn đến điểm số thấp ở chỉ số so khớp từ vựng.

Argument	Avg BLEU	Avg ROUGE-1	Avg ROUGE-2	Avg ROUGE-L
trigger	0.192	0.65	0.573	0.646
arg_subject	0.678	0.847	0.814	0.843
arg_time	0.275	0.906	0.652	0.904
arg_location	0.331	0.826	0.386	0.823

3. Models's results

Kết quả cho thấy pipeline đạt hiệu suất cao hơn đáng kể so với OneIE ở Trigger và Argument, trong khi Event type chênh lệch không nhiều. Tuy nhiên, ưu điểm của OneIE là thực hiện đồng thời cả ba tác vụ trong một mô hình duy nhất, giúp giảm chi phí tính toán và dễ dàng triển khai trong các hệ thống thực tế.

	Classification	Precision	Recall	F1-score
Pipeline	Trigger	0.6179	0.5668	0.5849
	Argument	0.8307	0.8201	0.8253
	Event type	0.8294	0.7911	0.8011
Joint Learning (OneIE)	Trigger	0.2269	0.6813	0.3171
	Argument	0.4792	0.6998	0.5398
	Event type	0.8084	0.7722	0.784

V. ERROR ANALYSIS

- Lỗi nhận diện trigger
- Lỗi xác định Argument
- Lỗi phân loại các loại sự kiện (event type)
- Lỗi do dữ liệu không đồng nhất
- Lỗi từ quá trình gán nhãn bằng LLM
- Lỗi từ mô hình trích xuất sự kiện

VI. CONCLUSION & PROPOSAL

- Tăng cường khả năng học vai trò argument
- Xử lý mất cân bằng nhãn
- Mở rộng hệ thống gán nhãn
- Rà soát và chuẩn hóa dữ liệu
- Cải thiện chất lượng gán nhãn bằng LLM
- Áp dụng các mô hình SOTA mạnh mẽ hơn

The background features three vertical bars on the left: a wide pink bar, a medium blue bar, and a narrow beige bar. In the top right corner, there is a grid of small pink dots that fades out towards the center.

THANK YOU